Prédiction des décès dus au COVID-19 grâce au Machine Learning

Enzo DE CARVALHO

Numéro d'inscription : 29448

2020-2021

Sommaire

Principe de la démarche

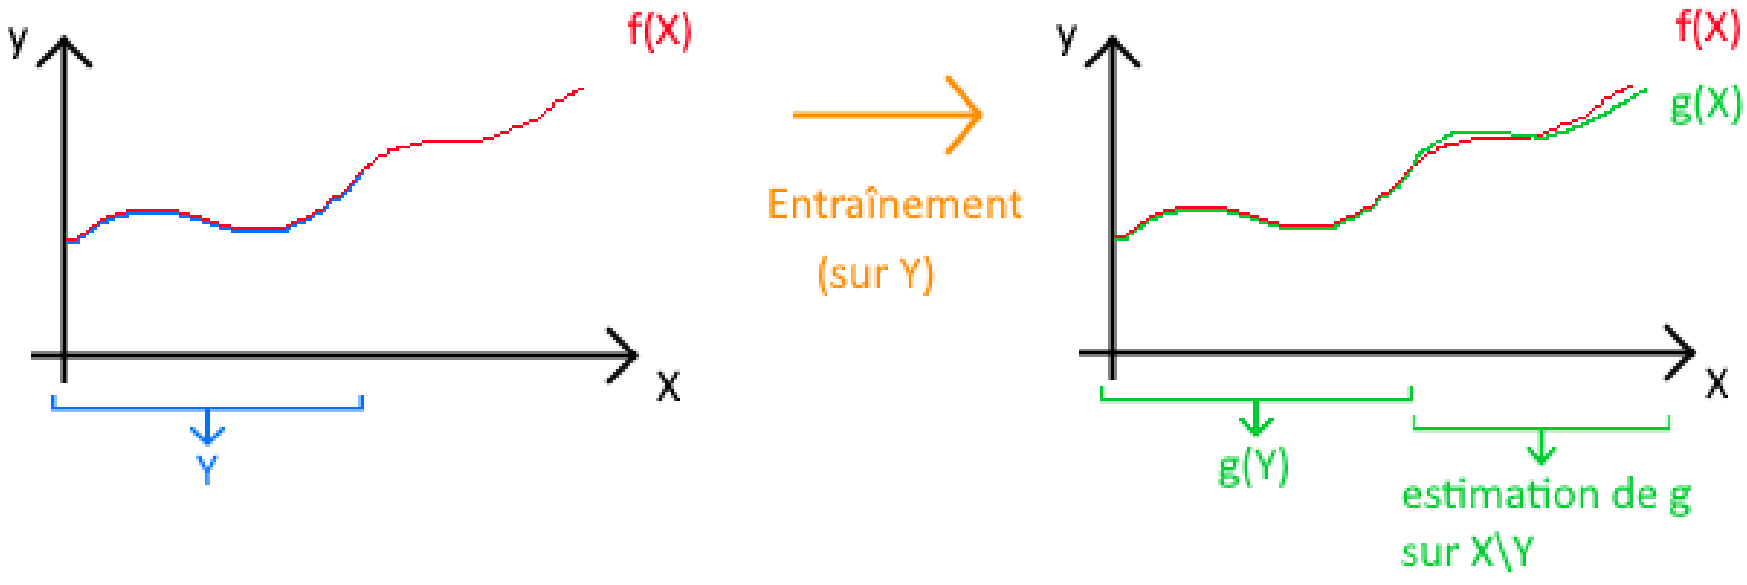

$\hookrightarrow$ le modèle $\hat{g}$ généralise les données connues Y fournies

Première approche : regression linéaire

En utilisant ElasticNet

Modèle :

$$\hat{g}_{deces}(\omega, t) = \omega_0 + \omega_1 t$$

t le temps

$\omega = \begin{pmatrix} \omega_0 \\ \omega_1 \end{pmatrix}$ un paramètre à déterminer

Première approche : regression linéaire

En utilisant ElasticNet

Modèle :

$$\hat{g}_{deces}(\omega, t) = \omega_0 + \omega_1 t$$

t le temps

$\omega = \begin{pmatrix} \omega_0 \\ \omega_1 \end{pmatrix}$ un paramètre à déterminer

Le modèle ElasticNet détermine alors ω
Le résultat dépend des hyperparamètres α et ρ

Première application

Prédictions entre le 2020/11/01 et 2020/12/16.

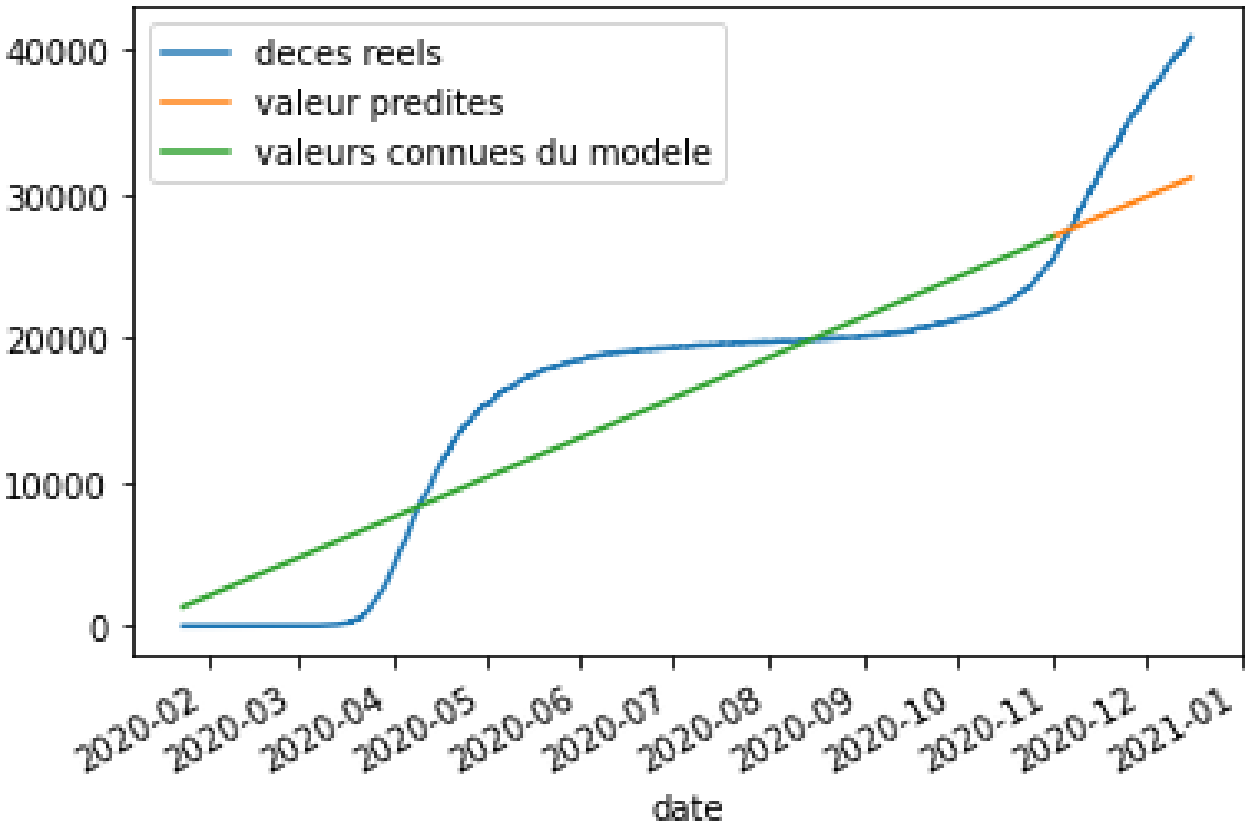

$\rho = 0.9$

$\alpha = 0.1$

Figure – Résultats peu satisfaisant...

SVR : Premier résultat

Modèle SVR (Regresseur à Support Vectoriel)

Hyperparamètres :

- C le paramètre de régularisation
- ϵ la taille du tube de « non-pénalité »
- γ paramètre du noyeau (`rbf` ici)

SVR : Premier résultat

Modèle SVR (Regresseur à Support Vectoriel)

Hyperparamètres :

- C le paramètre de régularisation
- ϵ la taille du tube de « non-pénalité »
- γ paramètre du noyeau (`rbf` ici)

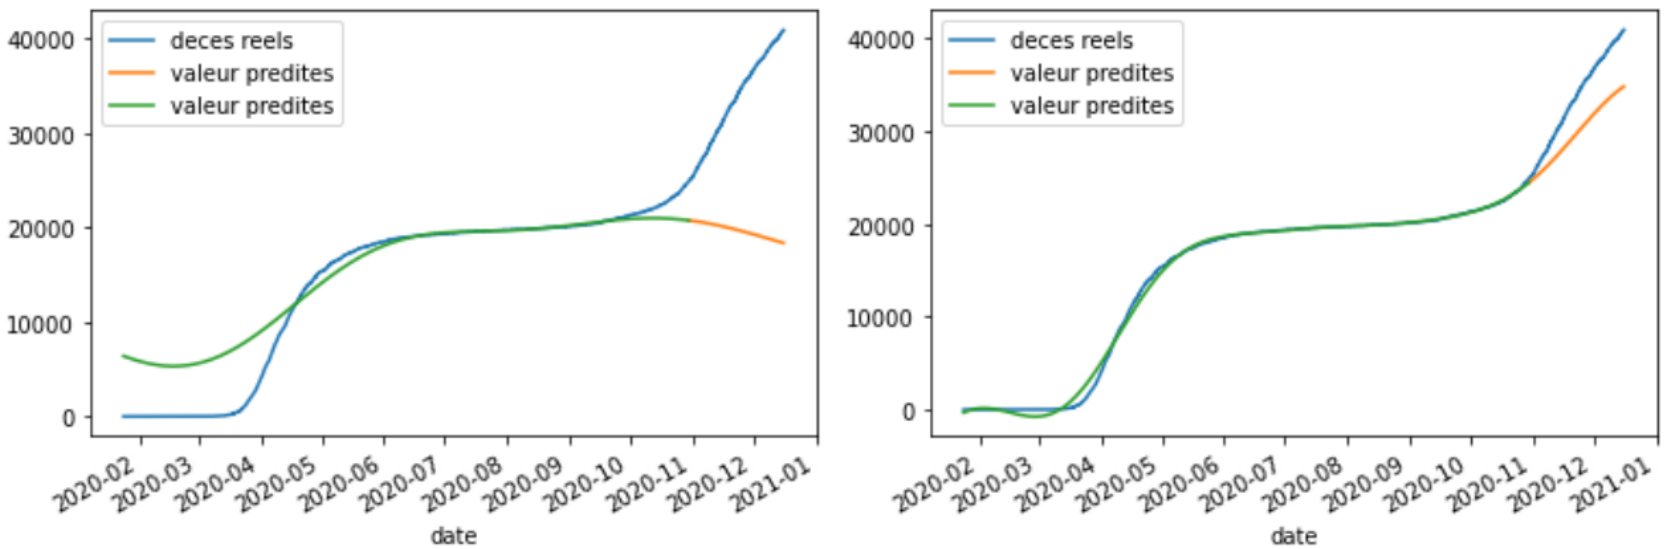

Figure – SVR avec $C = 100$, puis $C = 100000$

Validation Croisée

Grille d'hyperparamètres :

```
params = {'svr__C' : [10, 100, ...],
          'svr__eps' : [0.1, 0.01, ..], ... }
```

Validation Croisée

Grille d'hyperparamètres :

```
params = {'svr__C' : [10, 100, ...],
          'svr__eps' : [0.1, 0.01, ..], ... }
```

Pour une combinaison d'hyperparamètres :

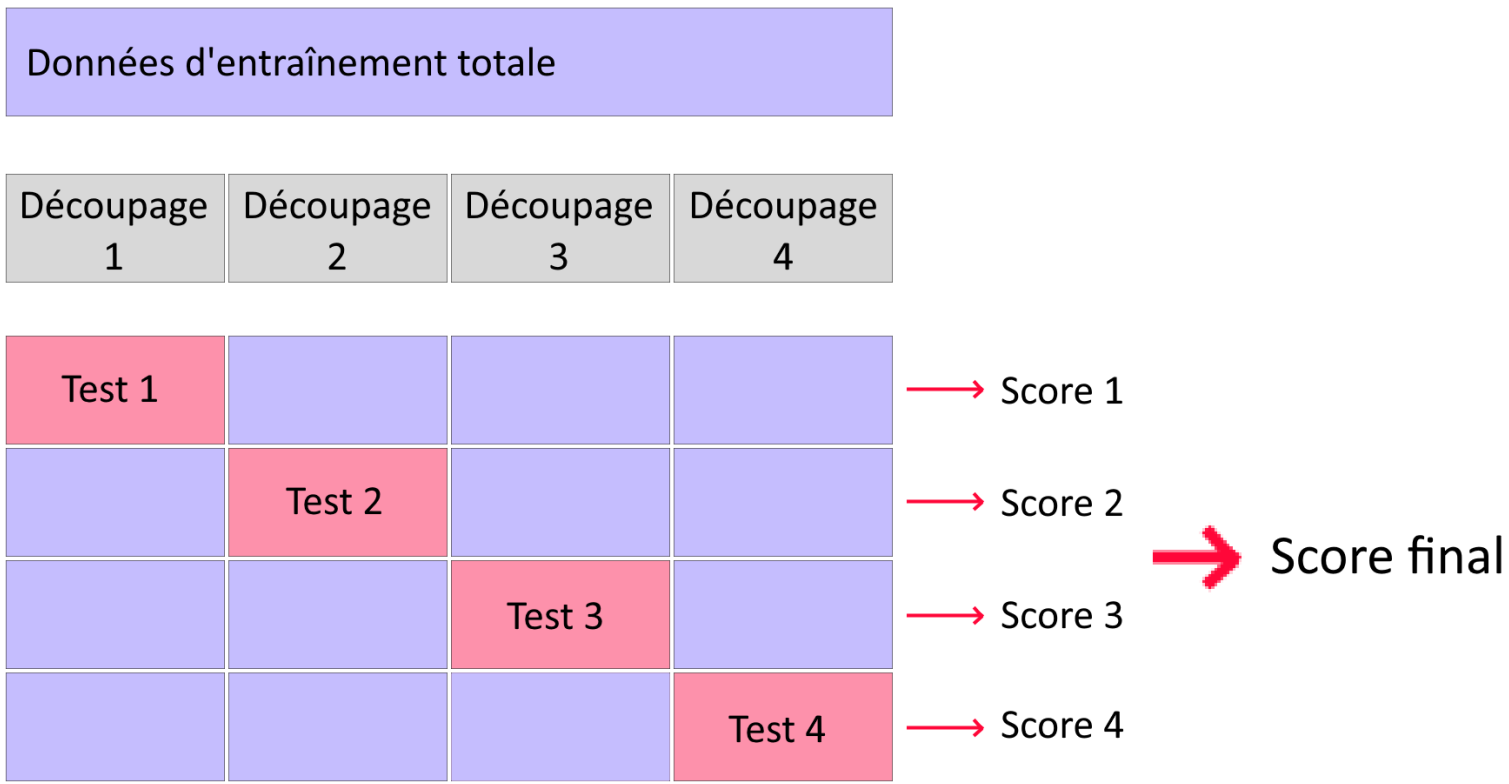

Stratégie pour la Validation Croisée

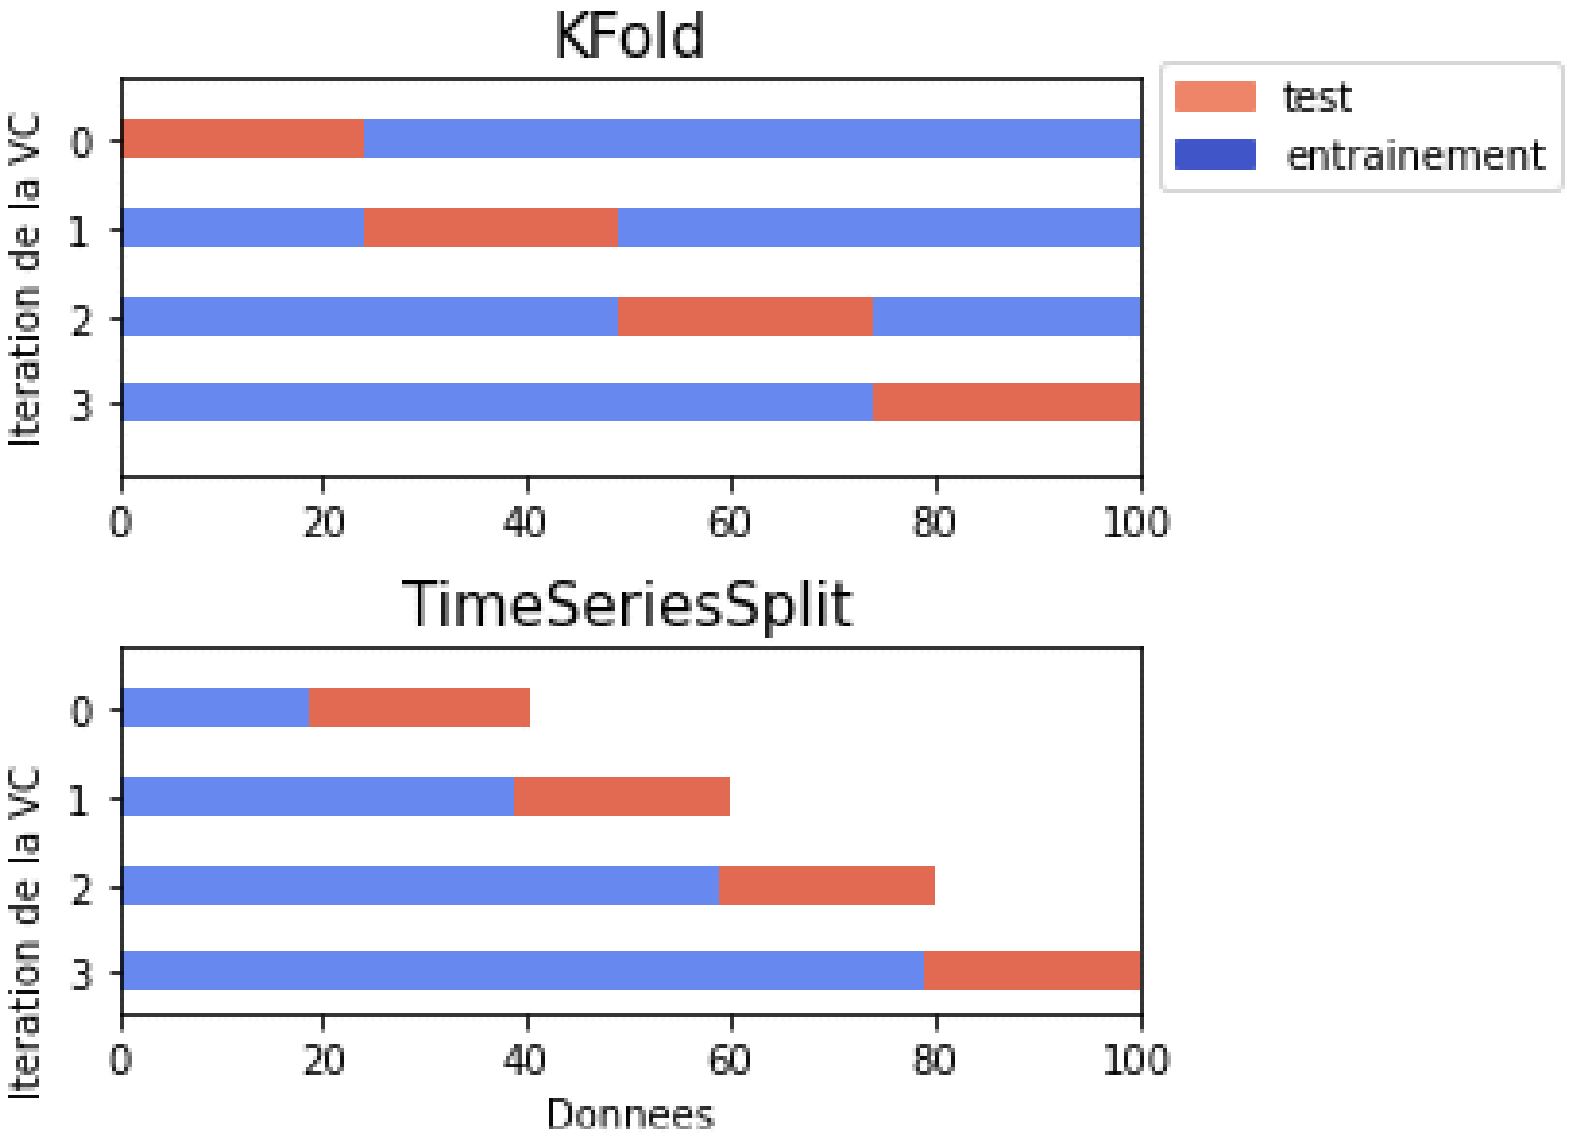

Application avec SVR

```
params = {'svr__C' : [10**i for i in range(1,8)]}
```

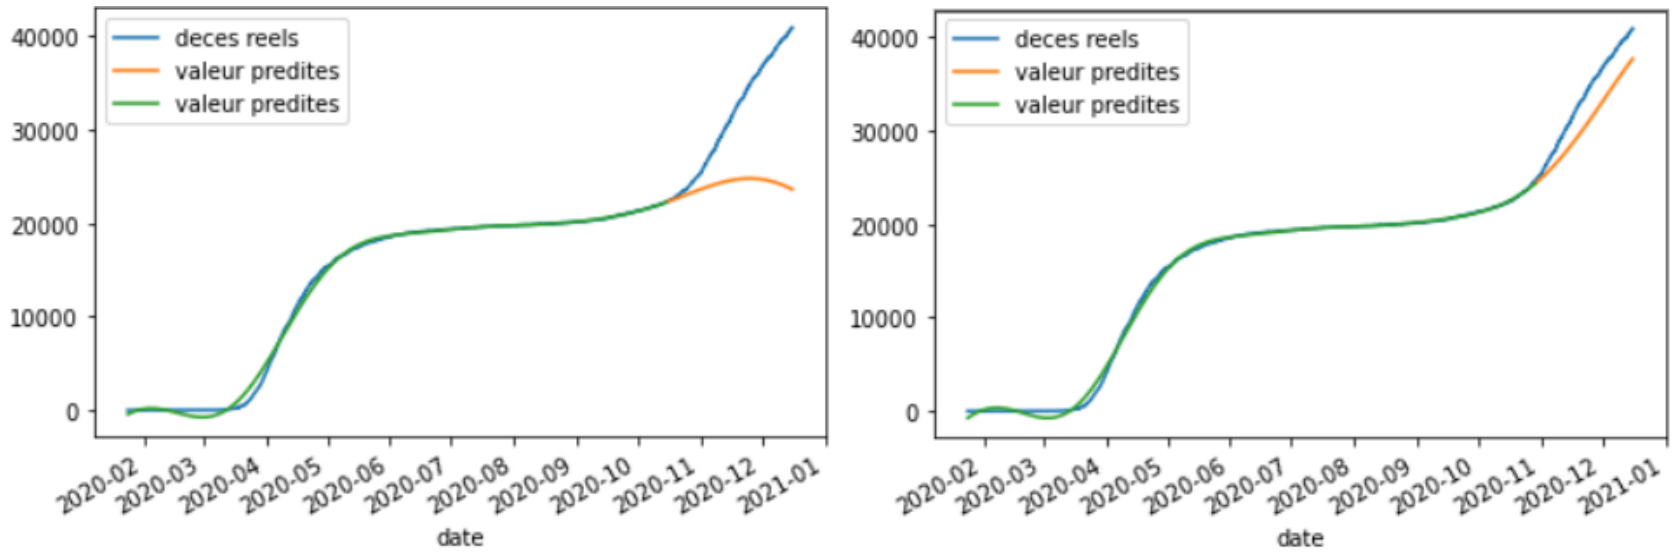

`{'svr__C' : 100000}` `{'svr__C' : 1000000}`

Figure – à partir du 15/10/2020, puis du 01/11/2020

⇒ Échec de généralisation

Prophet

Approche avec le modèle Prophet de Facebook

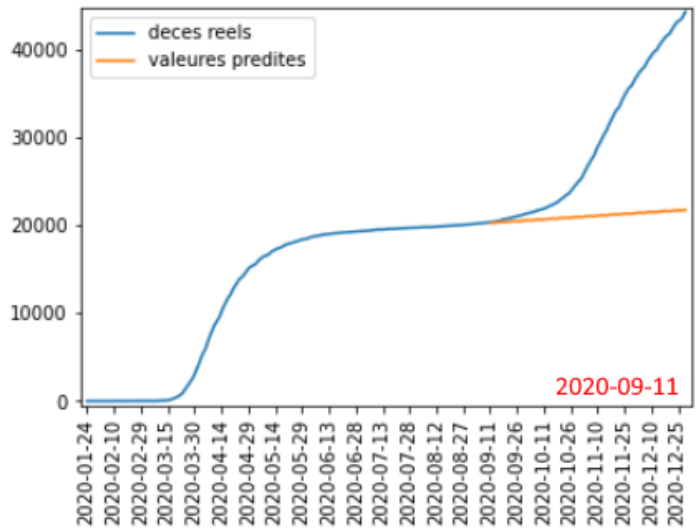

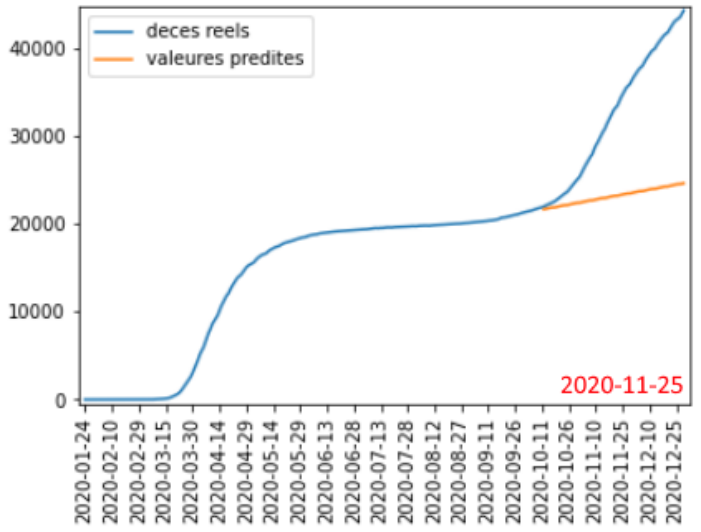

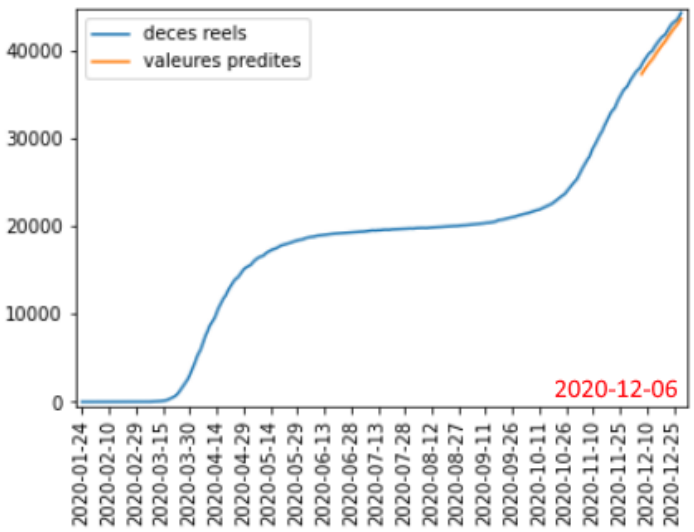

RegressorChain SVR

Approche multivariée avec RegressorChain

```
params = {
'svr__C' : [10**i for i in range(1,8)],
'svr__epsilon': [0.1,0.01,0.001]}
```

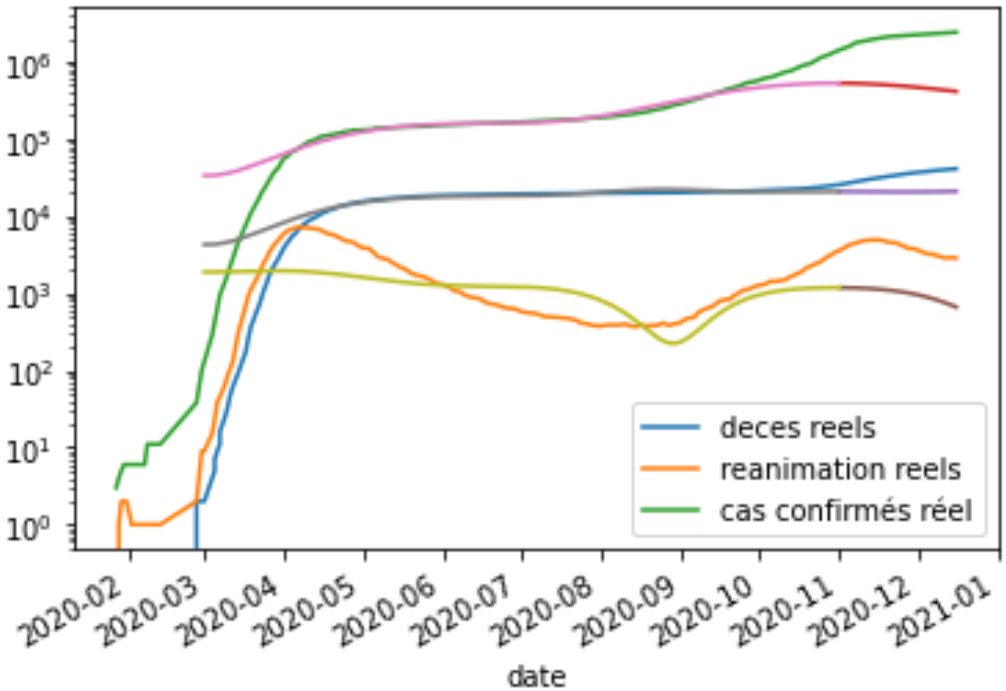

Figure – RegressorChain avec $C = 10000$ et $\epsilon = 0.001$

Réseau neuronal

Approche avec des réseaux neuronaux

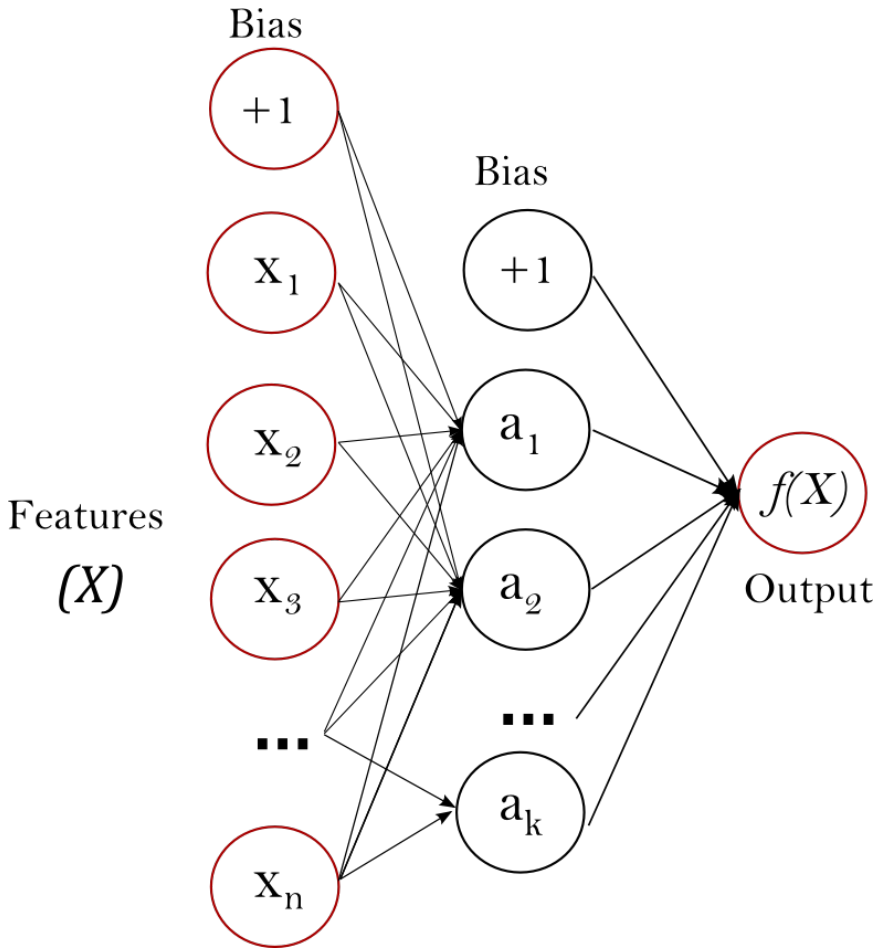

Application avec réseau neuronal

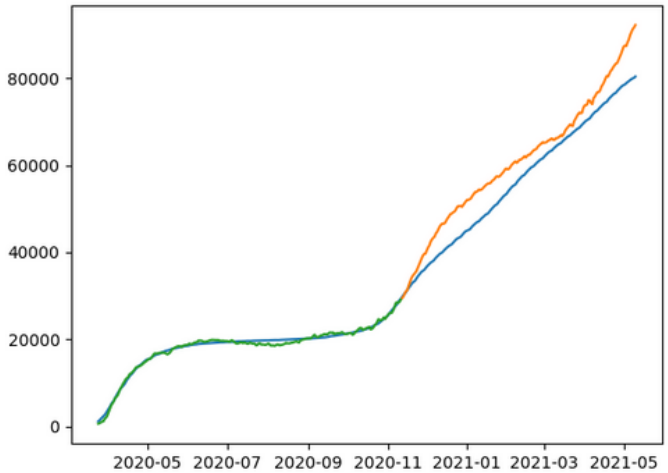

max_iter
100k

date
11/11/20

décalage
7j

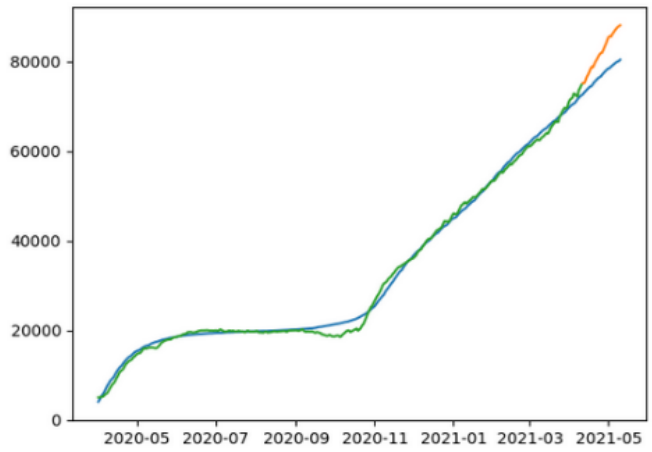

max_iter
90k

date
10/04/21

décalage
15j

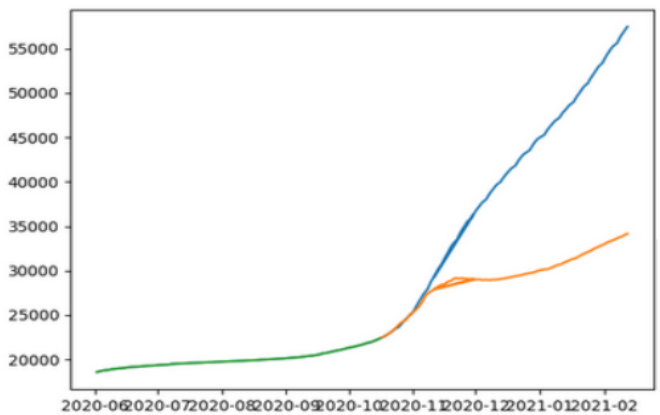

max_iter
90k

date
15/10/20

décalage
7j

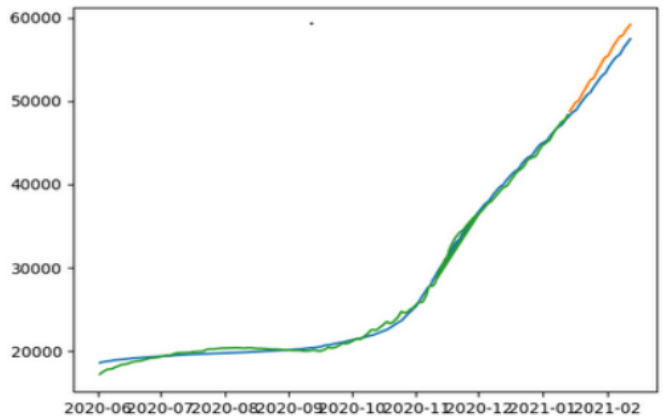

max_iter
90k

date
10/01/21

décalage
7j

Application avec réseau neuronal

Taux de corrélation entre
`total_cas_confirmes` et `total_deces_hopital` : `0.977939`

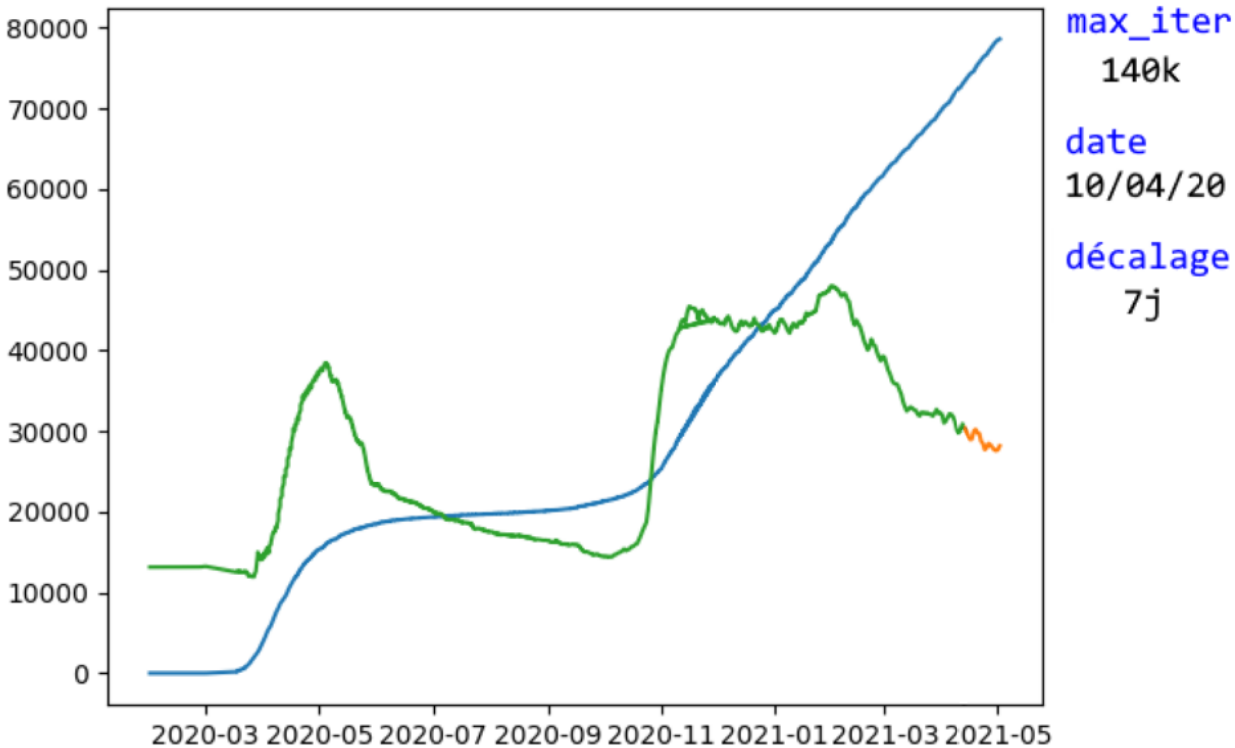

⇒ échec du modèle sans la courbe des cas confirmés

Conclusion

Résultats :

Conclusion

Résultats :

$\Rightarrow$ Prédictions justes sur les périodes sans variations

Conclusion

Résultats :

- $\Rightarrow$ Prédictions justes sur les périodes sans variations
- $\Rightarrow$ Difficulté de prédictions sans le point d'inflexion

fonction d'objectif d'ElasticNet

ElasticNet cherche ω tel que :

$$\min_{\omega} \frac{1}{2n_{deces}} ||\hat{g}_{deces}(\omega, t) - f(t)||_2^2 + \alpha\rho|\omega| + \frac{\alpha(1-\rho)}{2}||\omega||_2^2$$

α et ρ les hyperparamètres définissant le modèle,

f la courbe réelle des décès.

Détails sur la regression linéaire

```
params = {
    'elasticnet__alpha' : [i/100 for i in range(10,100)],
    'elasticnet__l1_ratio' : [0.5,0.8,0.9]}
```

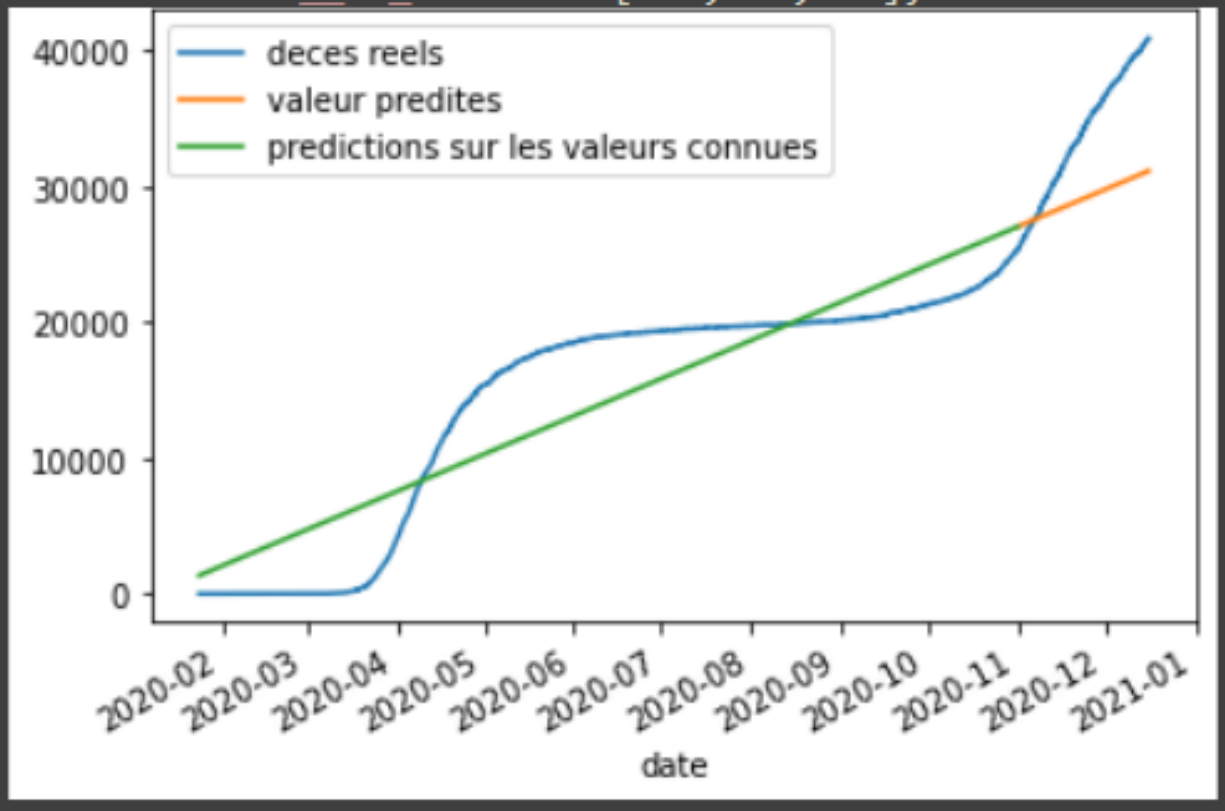


```
deces    622
dtype: int64
{'elasticnet__alpha': 0.1, 'elasticnet__l1_ratio': 0.9}
```

Détails sur la regression multivariée

```
model = make_pipeline(StandardScaler(), RegressorChain(SVR(), order=[0,2,1]
params = {'regressorchain__base_estimator__C': [10**i for i in range(2,8)],
          'regressorchain__base_estimator__epsilon': [0.001,0.1,0.01],
          'regressorchain__base_estimator__kernel': ['rbf']}
```

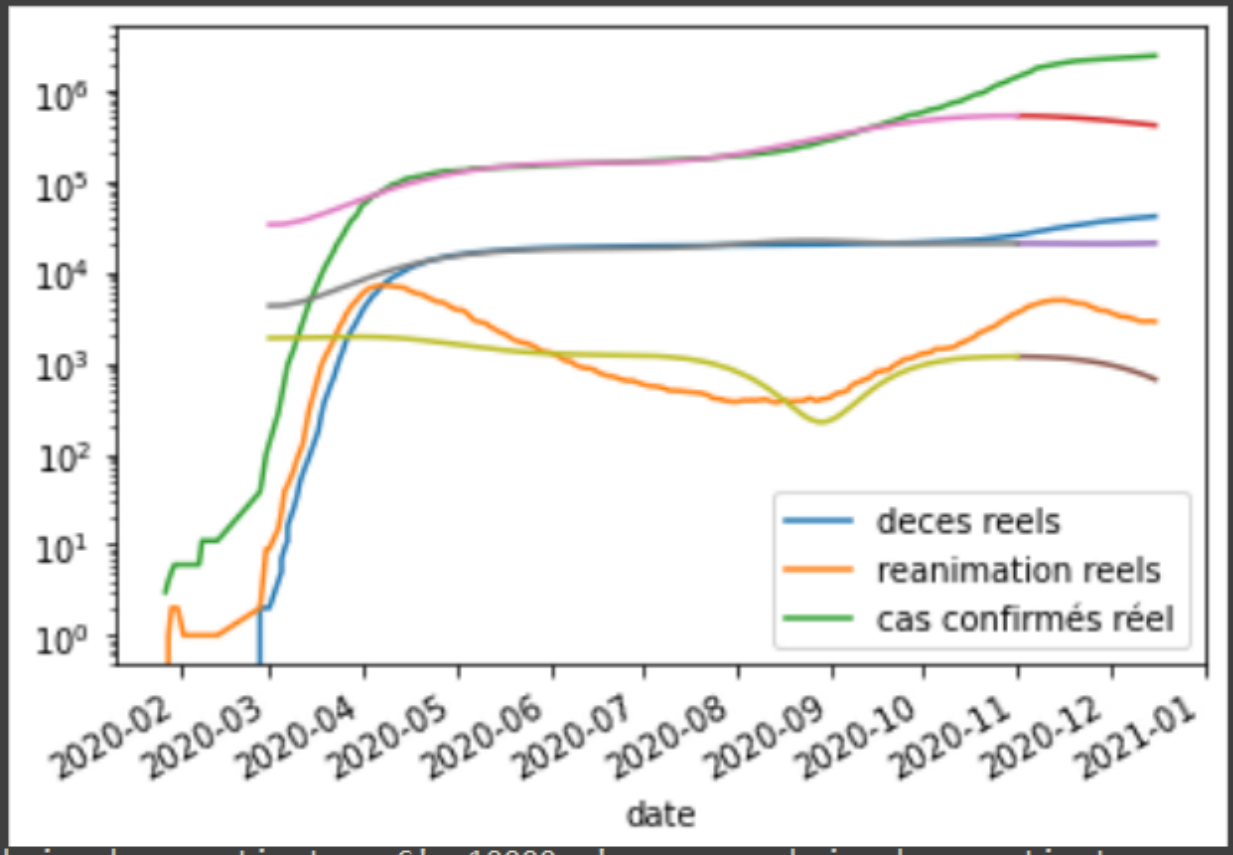


```
{'regressorchain__base_estimator__C': 10000, 'regressorchain__base_estimator__epsilon': 0.001,
'regressorchain__base_estimator__kernel': 'rbf'}
```

Annexes

```
##Methode SVR##
import matplotlib.pyplot as plt
import pandas as pd

from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import ElasticNet
from sklearn.svm import SVR
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import make_scorer
from sklearn.metrics import mean_squared_error
from sklearn.model selection import TimeSeriesSplit
```

Annexes

```
##############################################################################
svr = SVR()
params = {'svr__C' : [10**i for i in range(1,8)]}
```

```
############################Traitement de données#################################
cdata = pd.read_csv('covid_numbers.csv',index_col='date',parse_dates=True)
cdata = cdata[cdata['granularite']=='pays']

for i in cdata:
    if not (cdata[i].name in ["deces"]):
        cdata.drop([i], axis=1, inplace = True)

cdata = cdata.dropna(axis=0)

print(cdata.count())
cdata

############################Rangement de données#################################
```

Annexes

```
date = '2020-10-15'

y = cdata[:date]
X = pd.to_datetime(y.index)

size = len(X)

y = y.values.reshape(size,)
X = X.values.reshape(size,1)

X_train, y_train = X, y

model = make_pipeline(StandardScaler(), svr)
scorer = make_scorer(mean_squared_error, greater_is_better=False)
tscv = TimeSeriesSplit(n_splits=10)
grid = GridSearchCV(model, params, scorer, cv = tscv )

grid.fit(X_train, y_train)

x_prevu = pd.to_datetime(cdata[date:].index)
x_prevu = x_prevu.values.reshape(len(x_prevu),1)

cdata['deces'].plot(label="deces reels")
plt.plot(x_prevu,grid.predict(x_prevu),label="valeur predites")
plt.plot(X_train, grid.predict(X_train), label = "valeur predites")
plt.legend()
plt.show()
print(grid.best_params_)
```

Annexes

```
### Multi regresseur avec le modele SVR ###

import matplotlib.pyplot as plt
import pandas as pd
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVR
from sklearn.model_selection import GridSearchCV
from sklearn.multioutput import RegressorChain
from sklearn.metrics import make_scorer
from sklearn.metrics import mean_squared_error
from sklearn.model_selection import TimeSeriesSplit
```

Annexes

```
#########################################################################
tscv = TimeSeriesSplit(n_splits=15)
scorer = make_scorer(mean_squared_error, greater_is_better=False)
model = make_pipeline(StandardScaler(), RegressorChain(SVR(), order=[0,2,1]))
params = {'regressorchain__base_estimator__C': [10**i for i in range(2,8)],
          'regressorchain__base_estimator__epsilon': [0.001,0.1,0.01],
          'regressorchain__base_estimator__kernel': ['rbf']}

grid = GridSearchCV(model, params, cv = tscv, verbose = 1)

#########################################################################
cdata = pd.read_csv('covid_numbers.csv',index_col='date',parse_dates=True)

cdata = cdata[cdata['granularite']=='pays']
for i in cdata:
    if not (cdata[i].name in ["deces", "reanimation", "cas_confirmes"]):
        cdata.drop([i], axis=1, inplace = True)

cdata = cdata.dropna(axis=0)
```

Annexes

```
date = '2020-11-01'

Y = cdata['2020-03-01':date]
x = pd.to_datetime(Y.index)

x = x.values.reshape(len(x),1)

grid.fit(x,Y)

x_futur = pd.to_datetime(cdata[date:].index)
x_futur = x_futur.values.reshape(len(x_futur),1)

cdata['deces'].plot(label="deces reels")
cdata['reanimation'].plot(label="reanimation reels")
cdata['cas_confirmes'].plot(label="cas confirmés réel")

plt.yscale('log')
plt.legend()
plt.plot(x_futur,grid.predict(x_futur),label="valeur predites")
plt.plot(x, grid.predict(x),label="valeur predites")

print(grid.best_params_)
```