

Étude sur le propagation du Covid-19 avec machine learning

Pedro ALEXANDRINE

numero d'inscription : 41758

2020-2021

Sommaire

- 1 Première approche : simple regression
 - Validation croisée et hyperparamètres
 - Résultats avec SVR

- 2 Approche multivariées
 - Multiregresseur : 'RegressorChain'
 - Réseau neuronal

Utilisation faite de l'apprentissage automatique

Choix du modèle :
model

Utilisation faite de l'apprentissage automatique

Choix du modèle :

`model`

Entraînement sur données X :

`model.fit(X)`

Utilisation faite de l'apprentissage automatique

Choix du modèle :

`model`

Entraînement sur données X :

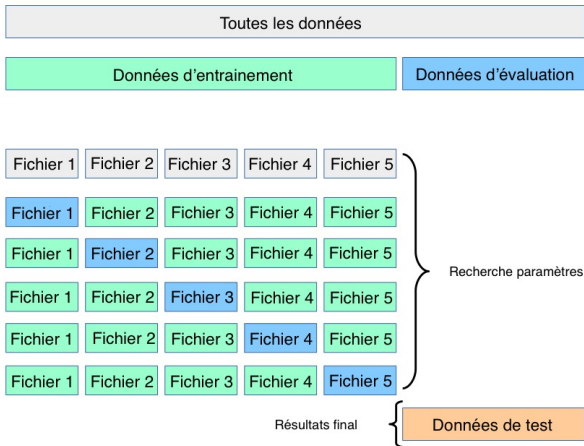
`model.fit(X)`

Utilisation du modèle :

`model.predict(nouveauX)`

Recherche du meilleur paramètre

Principe de la validation croisée:



SVR, premier résultat

Approche à l'aide du modèle SVR.

Noyau « rbf » → ajustement du paramètre C

— Modèle SVR (prédit les données entre le 02/12/20 et 16/12/20)




Figure: Premier résultat avec SVR et découpage inadapté, $C = 50k$

Découpage adapté pour la validation croisée

Remise en question de la méthode de découpage




Figure: Comparaison des découpages pour la validation croisée

SVR

Avec $C = 10^5$




Figure: À gauche: prediction avant point d'inflexion; à droite: après.

⇒ Prédiction inefficace du point d'inflexion.

RegressorChain SVR

Multiregresseur RegressorChain

Corrélation : Cas confirmé \rightarrow réanimation \rightarrow décès




Figure: Résultat avec SVR insatisfaisant

RegressorChain TheilSenRegressor

Changement de régresseur : meilleurs résultats





Figure: Prédiction avec et sans point d'inflexion

Principe du réseau neuronal

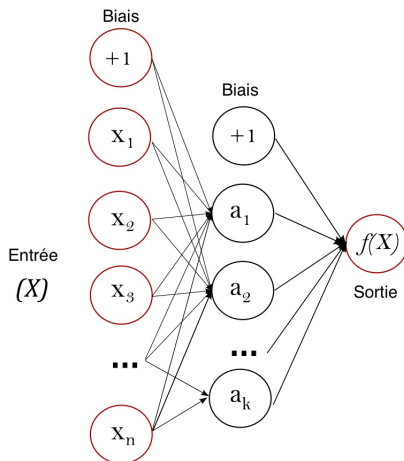




Illustration des idées



Décalage de courbes

Représentation avant et après décalage

date		date	
2020-03-17	175	2020-03-17	1100
2020-03-18	264	2020-03-18	1331
2020-03-19	372	2020-03-19	1696
2020-03-20	450	2020-03-20	1995
2020-03-21	562	2020-03-21	2314



Corrélation et Premier résultat

Corrélation cas confirmés et décès : 0.978







Figure: Tests avec et sans cas confirmés

Échec du modèle sans les cas confirmés → cohérent avec corrélation

Résultats

Réseaux neuronaux : Meilleurs paramètres



Neural network avec 7 jour de décalage; max_iter=90k

Augmentation du décalage

Résultats insatisfaisant




Figure: Tests avec 30 jours de décalage

Conclusion

Modèle peu fiable hors situation stabilisée ou début d'évolution

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from sklearn.pipeline import make_pipeline
from sklearn.neural_network import MLPRegressor
from pandas.plotting import
    register_matplotlib_converters
register_matplotlib_converters()
from sklearn.metrics import make_scorer
from sklearn.metrics import mean_squared_error
scorer = make_scorer(mean_squared_error,
    greater_is_better=False)
from sklearn.preprocessing import
    StandardScaler
from sklearn.model_selection import
    TimeSeriesSplit
from sklearn.model_selection import
    GridSearchCV
```

```

def timeshift_day(data,n):
    data.index = data.index.shift(periods = n,
    freq = 'D')

tscv = TimeSeriesSplit(n_splits=5)

covid = pd.read_csv('synthese-fra.csv',
    index_col='date',parse_dates=True)#,
    index_col='date',parse_dates=True)

for i in covid:
    if not (covid[i].name in ["
    total_deces_hospital", 'patients_reanimation',

```

```
patients_hospitalises', 'total_cas_confirmes'  
]):
```

```
    covid.drop([i], axis=1, inplace = True)
```

```
jour_decale=7
```

```
covid = covid.dropna(axis=0)
```

```
timeshift_day(covid["total_deces_hospital"], -  
    jour_decale)
```

```
full_size=covid.count()[0]
```

```
subject=['patients_reanimation',  
        'patients_hospitalises', '  
        total_cas_confirmes']
```

```
result=["total_deces_hospital"]
```

```
#start:2020-03-17
```

```
predit_jour='2021-04-01'
```

```
X = covid[:predict_jour][subject]
y = covid[result][:predict_jour]
y = y.values.reshape(381,)
X_result=covid[predict_jour:][subject]
y_result=covid[result][predict_jour:]
y_result = y_result.values.reshape(40,)

params={
    'mlpregressor__max_iter': [10000],
    'mlpregressor__tol': [0.0001],
    'mlpregressor__n_iter_no_change': [2],
}
```

```
model=make_pipeline(StandardScaler(),
    MLPRegressor())
```

```
grid=GridSearchCV(model, param_grid=params, cv=
```

```
tscv , scoring=scorer)
```

```
grid.fit(X,y)
```

```
timeshift_day(covid["total_deces_hospital"],  
              jour_decale)  
covid=covid[jour_decale:]
```

```
plt.figure()  
plt.plot(covid.index, covid["total_deces_hospital"  
                             "])  
plt.plot(covid.index[374:], grid.predict(covid['  
2021-03-25':][subject]))  
plt.plot(covid.index[:374], grid.predict(covid[:  
'2021-03-25'][subject]))
```

```
plt.show()
```

NN decodes datagouv copie.py

```
import matplotlib.pyplot as plt
import pandas as pd
from sklearn.model_selection import
    train_test_split
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import
    StandardScaler
from sklearn.svm import SVR
from sklearn.model_selection import
    GridSearchCV
from sklearn.linear_model import Lasso

covid = pd.read_excel('covid1.xlsx', index_col='
    date', parse_dates=True)
```



```
covid = covid[covid['granularite']=='pays']

covid.drop(['cas_ehpad', 'cas_confirmes_ehpad',
            'cas_possibles_ehpad', 'source_url',
            'deces_ehpad', 'reanimation',
            'gueris', 'source_nom',
            'nouvelles_hospitalisations',
            'nouvelles_reanimations', 'depistes',
            'maille_code', 'maille_nom',
            'source_archive', 'source_type'], inplace=True,
axis=1)

covid = covid.dropna(axis=0)

subject=['deces']

jour_prevu=75
```

```
size=covid.count()[0]-jour_prevu
X = covid.index[:size]
y = covid[:size][subject]
```

```
y = y.values.reshape(size)
X = X.values.reshape(size,1)
```

```
X_train, y_train=X, y
```

```
model=make_pipeline(StandardScaler(), SVR())
params={
    'svr__degree': [0],
    'svr__C': [600000],
}
```

```
grid = GridSearchCV(model, param_grid=params, cv
=4)
```

```
grid.fit(X_train , y_train)
```

```
x_prevu = covid.index[size:]  
x_prevu = x_prevu.values.reshape((len(x_prevu)  
    ,1)
```

covid_deces copie.py

```
import matplotlib.pyplot as plt  
import numpy as np  
import pandas as pd  
from matplotlib import pyplot as plt  
from sklearn.pipeline import make_pipeline  
from sklearn.preprocessing import  
    StandardScaler  
from sklearn.model_selection import  
    TimeSeriesSplit
```

```
from sklearn.svm import SVR
from sklearn.multioutput import RegressorChain
from sklearn.model_selection import
    GridSearchCV
from pandas.plotting import
    register_matplotlib_converters
register_matplotlib_converters()
from sklearn.metrics import make_scorer
from sklearn.metrics import mean_squared_error
from sklearn.linear_model import
    RANSACRegressor
scorer = make_scorer(mean_squared_error,
    greater_is_better=False)
from sklearn.linear_model import
    TheilSenRegressor

tscv = TimeSeriesSplit(n_splits=10)
```

```
covid = pd.read_excel('chiffre_covid_14032021.xlsx', index_col='date', parse_dates=True)#,
index_col='date', parse_dates=True)

covid = covid[covid['granularite']=='pays']

for i in covid:
    if not (covid[i].name in ["deces", '
cas_confirmes', 'reanimation', 'hospitalises'
]):
        covid.drop([i], axis=1, inplace = True)
covid=covid[5:]

covid = covid.dropna(axis=0)

subject=['hospitalises', 'cas_confirmes', '
reanimation']
result=["deces"]
```

```
size=255
```

```
X = covid[:size][subject]
```

```
y = covid[:size][result]
```

```
X_result=covid[size:][subject]
```

```
y_result=covid[size:][result]
```

```
y = y.values.reshape(size ,)
```

```
y_result = y_result.values.reshape(348-size ,)
```

```
params={
```

```
    'theilsenregressor__tol': [0.001],
```

```
    'theilsenregressor__random_state': [i for i  
in range(45)],
```

```
    'theilsenregressor__max_iter': [90000],
```

```
}
```

```
model=make_pipeline(StandardScaler(),  
    TheilSenRegressor())
```

```
grid=GridSearchCV(model,param_grid=params,cv=  
    tscv)
```

```
grid.fit(X,y)
```

```
p=covid[subject]
```

```
plt.figure()  
plt.plot(covid.index,covid['deces'])  
plt.plot(covid.index[size:],grid.predict(  
    X_result))
```

```
plt.show()
```

multi regressor tipe copie.py